

1. (10점) 다음 용어들의 의미를 서술 및 정의하세요.

Logistic regression: 데이터가 어떤 label 속할 확률을 0과 1 사이 값으로 예측/이를 통해 가능한 다른 label 부여

$$L(y, \hat{y}) = -y \log \hat{y} + (1-y) \log(1-\hat{y})$$

Backpropagation:

가라(배)를 역으로 하여 파라미터(ex. w, b)를 업데이트
gradient를 이용해 파라미터(ex. w, b)를 업데이트
하하여 loss를 줄이는 것.

parameter ↓
함수 ↓

Locality in CNN:

전체를 다 연결시키지 않고, Hidden Layer node와 모든 input을 연결하지 않고, 인접한 input들끼리만 연결하여 connection을 줄이는 것. (image 객체만 판별 사용)

Weight sharing in CNN:

다른 노드의 weight 값을 공유한다.

weight가 항상 같은 filter convolution을 진행한다.

2. (10점) 다음 activation 함수들의 정의를 쓰세요.

a. Sigmoid:

$$\sigma(z) = \frac{1}{1+e^{-z}}$$

b. Tanh:

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$

c. ReLU:

$$\text{ReLU}(x) = \max(0, x)$$

d. Leaky ReLU:

$$\text{Leaky ReLU}(x) = \max(0.01x, x)$$

$$\sigma(z) = \frac{1}{1+e^{-z}}$$

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$

$$\text{ReLU} = \max(0, x)$$

$$\text{Leaky ReLU}(x) = \max(0.01x, x)$$

3. (5점) 딥러닝에서 L2 regularization을 수학적으로 표현하고, gradient descent의 update 식과 관련하여 왜 "weight decay"로 불리는지 이유를 서술하시오.

원래 J에 $\frac{\lambda}{2m} \|W\|_2^2$ 을 더해준다

$$dW = (\text{from back prop}) + \frac{\lambda}{m} W$$

$$W = W - \alpha \cdot dW$$

$$= (1 - \alpha \cdot \frac{\lambda}{m}) W - \alpha \cdot (\text{backprop})$$

이므로 W가 줄어든다.

다만, $\lambda \uparrow \rightarrow W \downarrow \rightarrow R \downarrow$

너무 큰 λ 들이면 $W=0$ 이 되어 Underfitting 가능성 있음

$$J(W^{[1]}, b^{[1]}, \dots, W^{[L]}, b^{[L]}) = \frac{1}{m} \sum_{i=1}^m \mathcal{L}(\hat{y}^{(i)}, y^{(i)}) + \frac{\lambda}{2m} \sum_{l=1}^L \|W^{[l]}\|_F^2$$

$$\text{Frobenius norm: } \|W^{[l]}\|_F^2 = \sum_{i=1}^{n^{[l]}} \sum_{j=1}^{n^{[l-1]}} (w_{ij}^{[l]})^2 \quad W^{[l]}: (n^{[l]}, n^{[l-1]})$$

$$\text{Gradient descent: } dW^{[l]} = (\text{from backprop}) + \frac{\lambda}{m} W^{[l]} \quad \left(\because \frac{\partial \|W^{[l]}\|_F^2}{\partial W^{[l]}} = 2W^{[l]} \right)$$

$$W^{[l]} := W^{[l]} - \alpha \cdot dW^{[l]}$$

4. (10점) 트레이닝 및 테스트 단계에서의 dropout 기법을 각각 설명하고, 왜 regularization 효과
가 있는지를 서술하시오.

Training시 특정 노드를 임의로 정하여 connections를 끊고
update한다.
Test시 모든 노드를 사용한다.

regularization 효과: 한 feature에 의존하지 않고, weight를 spread 시키기
때문.

5. (10점) 아래 표에서 bias와 variance가 각각 어떻게 변화하는지를 +/- 로 표시하시오.

	bias / Variance		Bias	Variance
L1 Regularization	+	-	-	+
Deeper & larger networks	-	+	-	-
Dropout	+	-	+	+
Less training data	-	+	-	-
Dataset augmentation	+	+	+	+

$$1+6+20+28 = 48+7 = 55$$

5-a. (10점) 입력 영상 x와 필터 f가 다음과 같을 때, 다음 표의 연산을 수행하시오.

4	0	3
0	5	0
2	0	1

1	2	3	0	0
0	4	5	6	0
0	0	7	8	9
0	0	0	0	0
0	0	0	0	10

1	0	2
0	5	0
3	0	4

$$4+9+20+7 = 13+27 = 40$$

$$12+30+14+9 = 65$$

$$4+12+35 = 49$$

$$2+0+25+32 = 59$$


	$4+9+20+7=40$	$13+27=40$	$=65$	$=47$ (5)																																		
	Without zero-padding	$27+13$	With zero-padding																																			
Correlation	<table><tr><td>56</td><td>59</td><td>90</td></tr><tr><td>10</td><td>51</td><td>45</td></tr><tr><td>14</td><td>16</td><td>65</td></tr></table>	56	59	90	10	51	45	14	16	65	$15, 16+18+35$ $=34+35$ $20+40$	<table><tr><td>21</td><td>30</td><td>51</td><td>15</td><td>18</td></tr><tr><td>4</td><td>56</td><td>59</td><td>90</td><td>24</td></tr><tr><td>8</td><td>10</td><td>51</td><td>45</td><td>51</td></tr><tr><td>0</td><td>14</td><td>16</td><td>65</td><td>8</td></tr><tr><td>0</td><td>0</td><td>0</td><td>0</td><td>50</td></tr></table>	21	30	51	15	18	4	56	59	90	24	8	10	51	45	51	0	14	16	65	8	0	0	0	0	50	
56	59	90																																				
10	51	45																																				
14	16	65																																				
21	30	51	15	18																																		
4	56	59	90	24																																		
8	10	51	45	51																																		
0	14	16	65	8																																		
0	0	0	0	50																																		
Convolution	<table><tr><td>40</td><td>41</td><td>65</td></tr><tr><td>15</td><td>69</td><td>60</td></tr><tr><td>21</td><td>24</td><td>65</td></tr></table>	40	41	65	15	69	60	21	24	65	$20+27+10$ 45 55	<table><tr><td>50</td><td>0</td><td>0</td><td>0</td><td>0</td></tr><tr><td>8</td><td>65</td><td>16</td><td>14</td><td>0</td></tr><tr><td>51</td><td>45</td><td>59</td><td>10</td><td>8</td></tr><tr><td>24</td><td>90</td><td>51</td><td>56</td><td>4</td></tr><tr><td>18</td><td>15</td><td>51</td><td>30</td><td>21</td></tr></table>	50	0	0	0	0	8	65	16	14	0	51	45	59	10	8	24	90	51	56	4	18	15	51	30	21	
40	41	65																																				
15	69	60																																				
21	24	65																																				
50	0	0	0	0																																		
8	65	16	14	0																																		
51	45	59	10	8																																		
24	90	51	56	4																																		
18	15	51	30	21																																		

$$6+0+25+8 = 41$$

5-b. (5점) 최신 딥러닝 library에서 convolution 과 correlation을 혼동해서 사용하고 있고, 이렇게 해도 되는 이유는 무엇일까?

Correlation 계산을 CNN은 필터(F)를 찾아내는 것이 목표이므로, 계산상 간편하 / flip-flop을 애번 같은 F를 찾을 수 있는 Correlation을 사용하는 것 Convolution 계산 후만 찾아 에 더욱 용이하다.

7. (10점) 아래는 Lenet-5의 모델 architecture를 도식화한 것이다. 전체 학습 parameter의 수가 어떻게 되는가?



	Activation shape	#parameter
Input:	(32,32,3)	0
Conv1 (f=5, s=1)	(28,28,8)	$(5 \times 5 + 1) \times 8$
POOL1	(14,14,8)	0
Conv2 (f=5, s=1)	(10,10,16)	$(5 \times 5 + 1) \times 16$
POOL2	(5,5,16)	0
FC3	(120,1)	$4 \times 120 + 1$
FC4	(84,1)	$120 \times 84 + 1$
Softmax	(10,1)	$84 \times 10 + 1$

8. (10점) Gradient descent with momentum, RMSProp, ADAM optimizer를 각각 설명하시오.

Gradient descent with momentum:

$$V_d w_t = \beta \cdot dw_{t-1} + (1-\beta) dw_t$$

$$V_d b_t = \beta \cdot db_{t-1} + (1-\beta) db_t$$

과거 몇개의 gradient의 average를 가지고 mini Batch의 경우 여러 곳으로 뒤집힌 gradient를 Smooth하게 한다.

$$V_{dw} = \beta \cdot V_{dw} + (1-\beta) dw$$

$$\rightarrow W = W - \alpha \cdot V_{dw}$$

$$b = b - \alpha \cdot V_{db}$$

RMSProp: 이것도 Gradient를 $\sqrt{S_{dw}}$, $\sqrt{S_{db}}$ 로 나누어

$$S_{dw_t} = \beta_2 dw_{t-1}^2 + (1-\beta_2) dw_t^2$$

$$S_{db_t} = \beta_2 db_{t-1}^2 + (1-\beta_2) db_t^2$$

$$S_{dw} = \beta \cdot S_{dw} + (1-\beta) dw^2$$

$$W = W - \frac{\alpha \cdot dw}{\sqrt{S_{dw}}}$$

larger

smaller

ADAM optimizer

Momentum과 RMSProp을 합쳐,
bias correction을 적용한다.

$$W = W - \alpha \cdot \frac{V_{dw}^{corrected}}{\sqrt{S_{dw}^{corrected} + \epsilon}}$$

9. (10점) 입력 (x_1, x_2, \dots, x_n) , 출력 o_d , loss function이 $E = \sum_{d=1}^m (o_d - t_d)^2$ 일 때, gradient descent with momentum rule을 계산 하시오. (단, 필요한 gradient를 모두 계산하되, 이동평균의 bias correction은 무시해도 좋음)

$$o_d = w_0 + w_1 x_1^{(d)} + \dots + w_n x_n^{(d)} \quad E = \sum_{d=1}^m (o_d - t_d)^2$$

$$V_{dw} = \beta \cdot V_{dw} + (1 - \beta) dw$$

$$W = W - \alpha \cdot V_{dw}$$

10. (10점) 아래와 같은 2-layered network 에서 activation function은 ReLU, loss function $E = \sum_{d=1}^m (o_d - t_d)^2$ 일 때 (mini batch size = m), $dW^{(1)}, dB^{(1)}, dW^{(2)}, dB^{(2)}$ 를 계산하고, gradient update rule을 적용하시오.



$$\begin{aligned} x_1 \rightarrow & \left(Z^{(1)} = W^{(1)} X + B^{(1)} \right) \rightarrow \left(a^{(1)} = \text{ReLU}(Z^{(1)}) \right) \rightarrow \left(Z^{(2)} = W^{(2)} a^{(1)} + B^{(2)} \right) \rightarrow \left(a^{(2)} = \text{ReLU}(Z^{(2)}) \right) \\ x_2 \rightarrow & \hspace{10em} \hspace{10em} \hspace{10em} \hspace{10em} \hspace{10em} \hspace{10em} \hspace{10em} \hspace{10em} \rightarrow \text{Loss}(a^{(2)}, o_d) \end{aligned}$$

ReLU 미분 \rightarrow 1 (양수일때)
0 (음수일때)

$$a^{(2)} = t_d$$

$$da^{(2)} = \frac{\partial L}{\partial a^{(2)}} = E'(a^{(2)})$$

$$\frac{\partial L}{\partial Z^{(2)}} = \frac{\partial L}{\partial a^{(2)}} \cdot \frac{\partial a^{(2)}}{\partial Z^{(2)}} = E'(a^{(2)}) \cdot 1 = E'(t_d)$$


$$\frac{\partial L}{\partial B^{(2)}} = \frac{\partial L}{\partial Z^{(2)}} \cdot \frac{\partial Z^{(2)}}{\partial B^{(2)}} = dL^{(2)} \cdot 1 = dL^{(2)}$$

$$da^{(1)} = \frac{\partial L}{\partial a^{(1)}} = \frac{\partial L}{\partial Z^{(2)}} \cdot \frac{\partial Z^{(2)}}{\partial a^{(1)}} = dL^{(2)} \cdot W^{(2)}$$

$$\frac{\partial L}{\partial Z^{(1)}} = \frac{\partial L}{\partial a^{(1)}} \cdot \frac{\partial a^{(1)}}{\partial Z^{(1)}} = da^{(1)} \cdot 1 = da^{(1)} = dL^{(2)} \cdot W^{(2)}$$

$$\frac{\partial L}{\partial W^{(1)}} = \frac{\partial L}{\partial Z^{(1)}} \cdot \frac{\partial Z^{(1)}}{\partial W^{(1)}} = dZ^{(1)} \cdot X = (dL^{(2)} \cdot W^{(2)}) \cdot (x_1 + x_2)$$

$$\frac{\partial L}{\partial B^{(1)}} = \frac{\partial L}{\partial Z^{(1)}} \cdot \frac{\partial Z^{(1)}}{\partial B^{(1)}} = dZ^{(1)} \cdot 1 = dZ^{(1)} = dL^{(2)} \cdot W^{(2)}$$



$$x \rightarrow [z^{[0]} = W^{[0]}x + B^{[0]}] \rightarrow [a^{[0]} = \text{ReLU}(z^{[0]})] \xrightarrow{W^{[1]}, B^{[1]}} [z^{[1]} = W^{[1]}a^{[0]} + B^{[1]}] \rightarrow [a^{[1]} = \text{ReLU}(z^{[1]})] \rightarrow [L(a^{[1]}, y)]$$

$// (a^{[1]} - y)^2$

$$da^{[2]} = \frac{dL}{da^{[2]}} = 2(a^{[2]} - y)$$

$$\text{ReLU}' = \begin{cases} 1 & (x \geq 0) \\ 0 & (\text{else}) \end{cases}$$

$$dz^{[2]} = da^{[2]} \cdot \frac{da^{[2]}}{dz^{[2]}} = \begin{cases} 2(a^{[2]} - y) \cdot 1 & (z^{[2]} \geq 0) \\ 0 & \text{otherwise} \end{cases}$$

$$dW^{[2]} = dz^{[2]} \cdot \frac{dz^{[2]}}{dW^{[2]}} = \begin{cases} 2(a^{[2]} - y) \cdot a^{[1]T} & (z^{[2]} \geq 0) \\ 0 & \text{otherwise} \end{cases}$$

$$dB^{[2]} = dz^{[2]} \cdot \frac{dz^{[2]}}{dB^{[2]}} = \begin{cases} 2(a^{[2]} - y) & (z^{[2]} \geq 0) \\ 0 & (\text{otherwise}) \end{cases}$$

$$da^{[1]} = dz^{[2]} \cdot \frac{dz^{[2]}}{da^{[1]}} = \begin{cases} 2(a^{[2]} - y) \cdot W^{[2]} & (z^{[2]} \geq 0) \\ 0 & \text{otherwise} \end{cases}$$

$$dz^{[1]} = da^{[1]} \cdot \frac{da^{[1]}}{dz^{[1]}} = \begin{cases} 2(a^{[2]} - y) W^{[2]} & (z^{[2]} \geq 0, z^{[1]} \geq 0) \\ 0 & (\text{otherwise}) \end{cases}$$

$$dW^{[1]} = dz^{[1]} \cdot \frac{dz^{[1]}}{dW^{[1]}} = \begin{cases} 2(a^{[2]} - y) W^{[2]} \cdot X & (z^{[2]} \geq 0, z^{[1]} \geq 0) \\ 0 & \text{otherwise} \end{cases}$$


$$dB^{[1]} = dz^{[1]} \cdot \frac{dz^{[1]}}{dB^{[1]}} = \begin{cases} 2(a^{[2]} - y) W^{[2]} & (z^{[2]} \geq 0, z^{[1]} \geq 0) \\ 0 & \text{otherwise} \end{cases}$$

$$W^{[1]} = W^{[1]} - \alpha \cdot dW^{[1]}$$

$$B^{[1]} = B^{[1]} - \alpha \cdot dB^{[1]}$$

$$W^{[2]} = W^{[2]} - \alpha \cdot dW^{[2]}$$

$$B^{[2]} = B^{[2]} - \alpha \cdot dB^{[2]}$$



$$x \rightarrow [z^{[1]} = W^{[1]}x + B^{[1]}] \rightarrow [a^{[1]} = \text{ReLU}(z^{[1]})] \xrightarrow{W^{[2]}, B^{[2]}} [z^{[2]} = W^{[2]}a^{[1]} + B^{[2]}] \rightarrow [a^{[2]} = \text{ReLU}(z^{[2]})] \rightarrow [L(a^{[2]}, y)]$$

// $(a^{[2]} - y)^2$

$$da^{[2]} = \frac{dL}{da^{[2]}} = 2(a^{[2]} - y)$$

$$dz^{[2]} = da^{[2]} \cdot \frac{da^{[2]}}{dz^{[2]}} = \begin{cases} 2(a^{[2]} - y) \cdot 1 & (z^{[2]} \geq 0) \\ 0 & \text{otherwise} \end{cases}$$

$$dW^{[2]} = dz^{[2]} \cdot a^{[1]}$$

$$dB^{[2]} = dz^{[2]}$$

$$da^{[1]} = dz^{[2]} \cdot W^{[2]}$$

$$dz^{[1]} = da^{[1]} \cdot \text{ReLU}'(z^{[1]})$$

$$= \begin{cases} da^{[1]} \cdot (z^{[1]} \geq 0, z^{[2]} \geq 0) \\ 0 & (\text{otherwise}) \end{cases}$$

$$dW^{[1]} = dz^{[1]} \cdot x$$

$$dB^{[1]} = dz^{[1]}$$

$$W^{[1]} = W^{[1]} - \alpha \cdot dW^{[1]}$$



$$W^{[2]} = W^{[2]} - \alpha \cdot dW^{[2]}$$

$$B^{[1]} = B^{[1]} - \alpha \cdot dB^{[1]}$$

$$B^{[2]} = B^{[2]} - \alpha \cdot dB^{[2]}$$

문제 풀이하기.

10. (10점) 아래와 같은 2-layered network 에서 activation function은 ReLU, loss function $E = \sum_{d=1}^m (o_d - t_d)^2$ 일 때 (mini batch size = m), $dW^{[1]}, dB^{[1]}, dW^{[2]}, dB^{[2]}$ 를 계산하고, gradient update rule을 적용하시오.



$$da^{[2]} = \frac{dL}{da^{[2]}} = 2 \sum_{d=1}^m (a^{[2]} - t_d) \cdot 1$$

$$dz^{[2]} = da^{[2]} \cdot \frac{da^{[2]}}{dz^{[2]}} = \begin{cases} 2 \sum_{d=1}^m (a^{[2]} - t_d) \cdot 1 & (z^{[2]} \geq 0) \\ 0 & \text{otherwise} \end{cases}$$

$$dw^{[2]} = dz^{[2]} \cdot a^{[1]T} = \begin{cases} 2 \sum_{d=1}^m (a^{[2]} - t_d) \cdot a^{[1]T} & (z^{[2]} \geq 0) \\ 0 & \text{otherwise} \end{cases}$$

$$db^{[2]} = dz^{[2]}$$

$$da^{[1]} = w^{[2]T} dz^{[2]} = \begin{cases} w^{[2]T} \cdot 2 \sum_{d=1}^m (a^{[2]} - t_d) \cdot a^{[1]T} & (z^{[2]} \geq 0) \\ 0 & \text{otherwise} \end{cases}$$

$$dz^{[1]} = da^{[1]} \cdot \frac{ReLU'(z^{[1]})}{1} = \begin{cases} w^{[2]T} dz^{[2]} \cdot 1 & (z^{[1]} \geq 0, z^{[2]} \geq 0) \\ 0 & \text{otherwise} \end{cases}$$

$$dW^{[1]} = \begin{cases} dz^{[1]} \cdot x^T & (z^{[1]} \geq 0, z^{[2]} \geq 0) \\ 0 & \text{otherwise} \end{cases}$$

$$db^{[1]} = \begin{cases} dz^{[1]} & (z^{[1]} \geq 0, z^{[2]} \geq 0) \\ 0 & \text{otherwise} \end{cases}$$

$$w^{[1]} = w^{[1]} - \alpha dw^{[1]}$$

$$b^{[1]} = b^{[1]} - \alpha db^{[1]}$$

$$w^{[2]} = w^{[2]} - \alpha dw^{[2]}$$

$$b^{[2]} = b^{[2]} - \alpha db^{[2]}$$


9. (10점) 입력 (x_1, x_2, \dots, x_n) , 출력 o_d , loss fun. E 에 대해, gradient descent with momentum rule을 계산 하시오. (단, 필요한 gradient를 모두 계산하되, 이동평균의 bias correction은 무시해도 좋음)

$o_d = w_0 + w_1 x_1^{(d)} + \dots + w_n x_n^{(d)}$ $E = \sum_{d=1}^m (o_d - t_d)^2$

$W = W - \alpha \cdot \frac{\sqrt{S_{dw}}}{\sqrt{S_{dw}} + \epsilon} + \epsilon$

$V_{dw} = \beta \cdot V_{dw} + (1 - \beta) dw$

$W = W - \alpha \cdot V_{dw}$



$$da = \frac{dL}{da} = 2(a - y)$$

$$dw = da \cdot X = 2(a - y) \cdot X$$

$$db = da \cdot 1 = 2(a - y)$$

$$V_{dw} = \beta \cdot V_{dw} + (1 - \beta) dw$$

$$V_{db} = \beta \cdot V_{db} + (1 - \beta) db$$

$$W = W - \alpha \cdot V_{dw}$$

$$b = b - \alpha \cdot V_{db}$$

9. (10점) 입력 (x_1, x_2, \dots, x_n) , 출력 o_d , loss function이 E일 때, gradient descent with momentum을 계산 하시오. (단, 필요한 gradient를 모두 계산하되, 이동평균의 bias correction은 무시해도 좋음) $\rightarrow V_{dw}$ 구하러?

$$o_d = w_0 + w_1 x_1^{(j)} + \dots + w_n x_n^{(j)} \quad E = \sum_{d=1}^m (o_d - t_d)^2$$

gradient descent

$$V_{dw} := \beta V_{dw} + (1-\beta) dW$$

$$V_{db} := \beta V_{db} + (1-\beta) db$$

$$\text{initial } V_{dw} = 0$$

$$V_{db} = 0$$

$$w := w - \alpha V_{dw}$$

$$b := b - \alpha V_{db}$$

$$\text{Let } X = (x_1 \dots x_n)$$

identity function

$$X \rightarrow \boxed{Z = WX + b} \rightarrow \boxed{O_d = g(Z)} \rightarrow L(O_d, Y)$$

$$dO_d = 2 \sum_{d=1}^m (O_d - t_d)$$

$$dZ = dO_d \quad \frac{dO_d}{dZ} = 1$$

$$dW = dZ \cdot X^T = 2 \sum_{d=1}^m (O_d - t_d) X^T$$

$$db = dZ = 2 \sum_{d=1}^m (O_d - t_d)$$

$$V_{dw} = \beta V_{dw} + (1-\beta) \cdot 2 \sum_{d=1}^m (O_d - t_d) X^T$$

$$V_{db} = \beta V_{db} + (1-\beta) \cdot 2 \sum_{d=1}^m (O_d - t_d)$$